UNIVERSITÉ LIBRE DE BRUXELLES

Devoir de Philosophie des Sciences

Professeur :
Axel CLEEREMANS
Jean-Noël Missa

Étudiante :
Giacominao GRANDOLFO - 000449111

PHILB315 - Philosophie des sciences cognitives

Faculté des sciences Psychologiques et de l'Éducation - Année académique 2021-2022

Introduction

C'est en découvrant le premier cours en ligne de Stanislas Dehaene au collège de France « Le cerveau statisticien : la révolution Bayésienne en sciences cognitives » que je me suis intéressée au sujet de ce présent travail. Tout chercheur qui porte de l'intérêt au bayésianisme sera très vite saisi de la richesse et la complexité de cet univers. Je me réjouis de n'être qu'au début de mes découvertes, aspirant déjà à intégrer ce mode de raisonnement rationnel à mon quotidien ainsi qu'à utiliser cette approche statistique pour analyser, je l'espère, mes futures recherches. Cette « formule du savoir » (Le Nguyen, 2018) soulève à mon sens deux axes de questionnement en philosophie des sciences. Le premier concerne l'analyse statistique qui oppose bayésiens et fréquentistes. Le second repose sur la question du pouvoir unificateur de « la théorie du cerveau bayésien » en sciences cognitives.

Je commencerai cette dissertation par une description du bayésianisme, je dirai un mot bref sur le débat statistique pour ensuite m'intéresser à «la théorie du cerveau bayésien » et au débat qu'elle soulève.

Le bayésianisme

Thomas Bayes, un mathématicien du 18ème a donné son nom à la théorie bayésienne. Cette théorie concerne la probabilité d'une hypothèse. La formule écrite par Bayes n'est pas celle que l'on utilise aujourd'hui lorsqu'on évoque ce théorème. En réalité, c'est au mathématicien Pierre Simon Laplace que l'on doit la formule finale quelques années plus tard. Il retourne la formule originale de Bayes qu'il appelle d'ailleurs « la probabilité inverse ». Sa particularité est de vouloir remonter en marche arrière depuis les « états du monde ». Contrairement aux formules fréquentistes qui cherchent à travers une logique déductive à propager l'incertitude des évènements depuis leur cause jusqu'à leur conséquence, la logique bayésienne utilise l'induction pour établir la probabilité d'une cause sachant sa conséquence. Dans son livre « Mémoire sur la probabilité des causes par les évènements », Laplace écrit de fait « je me propose de déterminer la probabilité des causes par les évènements, matière neuve à bien des égards et qui mérite d'autant plus d'être cultivée que c'est principalement sous ce point de vue que la science des hasards peut être utile dans la vie civile » (Laplace, 1749).

Ensuite, son contemporainphysicien Edwin Thompson Jaynes formuleune série d'implications pour les méthodes bayésiennes en se fondant sur le théorème de Cox-Jaynes et sa notion centrale de plausibilité (Roussel, 2019). Dans son premier chapitre intitulé « Raisonnement déductible et plausible », Jaynes(2003) introduit ses idées par l'exemple trivial d'un policier qui

assiste à une scène de vol et qualifie immédiatement de malhonnête une personne qu'il voit sortir par la fenêtre de la bijouterie, un sac à la main et l'alarme retentissante. « Dans cet ouvrage, nous serons en mesure de faire état de nouveaux progrès utiles et encourageants, dans lesquels les jugements intuitifs contradictoires sont remplacés par des théorèmes définis, et les procédures ad hoc sont remplacées par des règles qui sont déterminées de manière unique par de très élémentaires – et pratiquement incontournables – critères de rationalités. Toutes les discussions sur ces questions commencent par donner des exemples du contraste entre le raisonnement déductif et le raisonnement plausible. » (Jaynes 2003).

Selon lui, comme on l'attribue généralement à l'Organon d'Aristote (4è siècle B. J.-C.), le raisonnement déductif peut être analysé en définitive comme l'application répétée de deux syllogismes forts :

1: Deductive and Plausible Reasoning

$$\frac{\begin{array}{c}\text{If } A \text{ is true, then } B \text{ is true}\\ A \text{ is true}\end{array}}{\text{Therefore, } B \text{ is true}} \qquad (1\text{–}1)$$

and its inverse:

$$\frac{\begin{array}{c}\text{If } A \text{ is true, then } B \text{ is true}\\ B \text{ is false}\end{array}}{\text{Therefore, } A \text{ is false}} \qquad (1\text{–}2)$$

Ces deux raisonnements sont ceux que l'on utiliserait tout le temps mais nous n'avons pratiquement jamais la bonne quantité d'information pour nous les permettre. Nous tombons souvent dans des raisonnements logiquement plus faibles (Jaynes, 2003) :

$$\frac{\begin{array}{c}\text{If } A \text{ is true, then } B \text{ is true}\\ B \text{ is true}\end{array}}{\text{Therefore, } A \text{ becomes more plausible}} \qquad (1\text{–}3)$$

Dans ce dernier raisonnement, il n'y a pas d'évidence pour prouver que A est vrai mais la vérification de l'une de ses conséquences (B is true) augmente notre confiance en A (Jaynes, 2003).

Ainsi, il semblerait que le langage statistique ait toujours été à la recherche d'une certaine capacité à saisir l'incertitude. Comme le rappelle De Scheemaekere (2019) dans ses « fondements philosophiques du concept de probabilité », « l'incertitude est une composante majeure de la vie», la probabilité est un élément essentiel pour y faire face, non seulement d'un point de vue scientifique mais aussi philosophique. Il me semble que c'est précisément ce que propose la

statistique bayésienne avec une conception du raisonnement qui inclut la « notion de degré raisonnable de croyance à priori » (Dehaene, 2012). Dehaene (2012) exprime cela par « la mesure de la connaissance subjective, c'est-à-dire la plausibilité d'une interprétation par rapport à une autre ». Selon lui, « si l'évolution du cerveau a conduit à des règles cohérentes de manipulation de la plausibilité, ces règles doivent approximer les règles fondamentales de la probabilité » (Dehaene, 2012).

Ces règles sont des fondements mathématiques qu'il ne me semble pas utile de rappeler dans ce bref travail. Je rappellerai cependant la formule de Bayes en hommage à son élégance mathématique et à l'encre qu'elle a fait couler depuis. Elle a de particulier que les observations et les hypothèses jouent des rôles strictement symétriques et qu'on peut dès lors inverser le procédé: étant donné les données de l'hypothèse, quelle est la probabilité de l'hypothèse ?

On peut l'écrire comme ceci avec D pour données et H pour hypothèse :

$$p(H|D) \ \alpha \ p(D|H)\, p(H)$$

On peut la lire comme ceci : la probabilité de l'hypothèse étant donné les données est proportionnelle à la probabilité des données étant donnée l'hypothèse fois la probabilité de l'hypothèse. Dehaene (2012) explique qu'H, à droite est la probabilité à priori (prior en anglais) de l'hypothèse H, sa plausibilité avant même d'avoir les données (D). À gauche de la formule, c'est la probabilité « à postériori » qui est la nouvelle plausibilité de l'hypothèse qui apparait après avoir observé les données D. « À postériori » ne fait pas référence à la temporalité (on avait peut-être les données depuis longtemps) mais à la bonne manière de réviser nos croyances en tenant comptedes données D (Dehaene, 2012). C'est en fait un des points clés de cette formule, elle se met à jour à chaque nouvelle donnée reçue pour favoriser à travers le facteur de Bayes une hypothèse plutôt qu'une autre. Certains appellent cela la danse des crédances (Le Nguyen, 2018).

Dehaene fait l'éloge de cette formule en nous rappelant un concept fondamental de philosophie des sciences qui énonce qu'une théorie doit être falsifiable. Ce qui explique tout, n'explique rien. En effet, le système mathématique de la théorie bayésienne est tel qu'il privilégiera toujours l'hypothèse la plus parcimonieuse en termes de paramètres. Cela explique la référence fréquente au rasoir d'Ockham lorsque l'on se documente sur la bayésianisme. Ce principe philosophique veut que la solution la plus simple soit toujours préférée, la formule bayésienne est construite de manière à appliquer ce principe.

Approche statistique fréquentiste et bayésienne

Le bayésiannisme et le fréquentisme (appelée l'approche classique) sont deux grandes écoles d'inférences statistique basées sur « des postulats philosophiques et des méthodes mathématiques fondamentalement différentes » (Sprenger, 2016). Comme expliqué plus haut, l'inférence bayésienne se base sur la crédibilité d'une hypothèse alors qu'« une inférence fréquentiste est valide si, sur le long terme, la procédure qui en est à la base ne mène que rarement à des conclusions incorrectes » (Sprenger, 2016). Même si les méthodes du bayesianisme sont utilisées depuis une trentaine d'années « avec un succès croissant dans des domaines aussi divers que la génomique, le diagnostic médical, les géosciences, ou les sciences cognitives (cette liste est loin d'être exhaustive) » (Drouet, 2016), et que « les bayésiens semblent gagner haut la main d'un point de vue purement fondamental, il n'est pas évident que leurs méthodes constituent les meilleures solutions pour la pratique scientifique» (Sprenger, 2016). Il semblerait que ce soit entre autres la crainte d'intégrer une certaine subjectivité à travers le degré de croyance dans un raisonnement scientifique qui effraye les adaptes de Fisher, Pearson et Neyman. Une partie de la communauté scientifique aurait « peur que des intérêts externes affectent les inférences » (Sprenger, 2016).

Malgré son règne sans partage depuis le XXème siècle, le fréquentisme fait l'objet de nombreuses critiques, l'une des principales étant celle du « biais de sélection causé par le fait que seuls les travaux conclusifs sont publiés » (Le Nguyen, 2018). Le Nguyen soulève également de manière amusante une critique de la p-valeur : « si l'on prenait la p-value vraiment au sérieux, alors on devrait finir par rejeter toutes les théories scientifiques, y compris celles qui sont vraies ». Selon lui, la science nous dit que les théories doivent être testées « encore et encore », « or, avec un seuil de 0,00003 %, chaque expérience a une probabilité 0,00003 % de rejeter une théorie vraie qu'elle teste ». Si on suit ce principe à la lettre, une théorie vraie finira par être rejetée au bout de quelques millions d'essais.

De son côté, le bayésianisme risque-t-il de fragiliser les sciences avec un degré de subjectivité incontrôlable ? Il semble difficile de trancher le débat ; fort heureusement, la majorité de la communauté scientifique est animée par un désir d'honnêteté intellectuelle et semble constamment remanier les sciences, lentement mais surement vers les idées les plus raisonnables.

Le cerveau bayésien

La littérature sur ce sujet laisse apparaître le rôle fondamental des sciences cognitives comme faisant le lien entre une problématique mathématique et les questions philosophiques

qu'elle soulève. Effectivement, la théorie d'origine mathématique du cerveau bayésien soulevant des questionnements philosophiques profonds se propose depuis quelques années d'expliquer les processus principaux qui sous-tendent le fonctionnement de l'esprit, au cœur des sciences cognitives. Dehaene (2012) ira jusqu'à parler de « révolution bayésienne » à son sujet. Elle est une approche computationnelle issue des principes du traitement prédictif. Elle propose une formulation mécanistique et mathématique de ces processus cognitifs et suppose que le cerveau encode des croyances (états probabilistes) pour générer des prédictions à propos des entrées sensorielles, puis utilise les erreurs de prédictions pour mettre à jour ses croyances (Bottemanne et al., 2021). La théorie du cerveau bayésien (Bayesian Brain theory) est aujourd'hui l'une des approches les plus populaires en neurosciences pour représenter les processus complexes sous-tendant la perception, la prise de décision et l'apprentissage, trois domaines fondamentaux de la cognition (Clark, 2015).

En outre, cette théorie repose sur l'idée que le cerveau utilise des croyances afin de générer des prédictions (aussi nommées anticipations, ou attentes) sur les entrées sensorielles que le corps va expérimenter (Friston, 2005). Ces croyances sont ensuite mises à jour en fonction des erreurs de prédiction provoquées par les entrées sensorielles, permettant au cerveau de s'adapter aux changements dans son environnement. En d'autres mots, appliquée au traitement prédictif, la théorie bayésienne permet de comprendre comment le cerveau génère des inférences afin de déterminer la probabilité des informations sensorielles qu'il va recevoir au fur et à mesure de ses expériences, et comment il modifie ses croyances en fonction de ces informations (Bottemanne et al., 2022).

Les corrélats neuronaux

Le neuroscientifique Wilfrid Rall démontre parallèlement que les arborisations dendritiques à l'extrémité des neurones modifient le traitement synaptique et le transfert d'information électrique (Rall, 1962). Ces découvertes du début au milieu du XXe siècle révolutionnent la compréhension du rôle des neurones en montrant que l'activité cérébrale est générée par le traitement automatisé de l'information au sein de réseaux neuronaux, et que les connexions synaptiques déterminent le type de message transmis par l'activité cérébrale (Bottemanne et al., 2022).

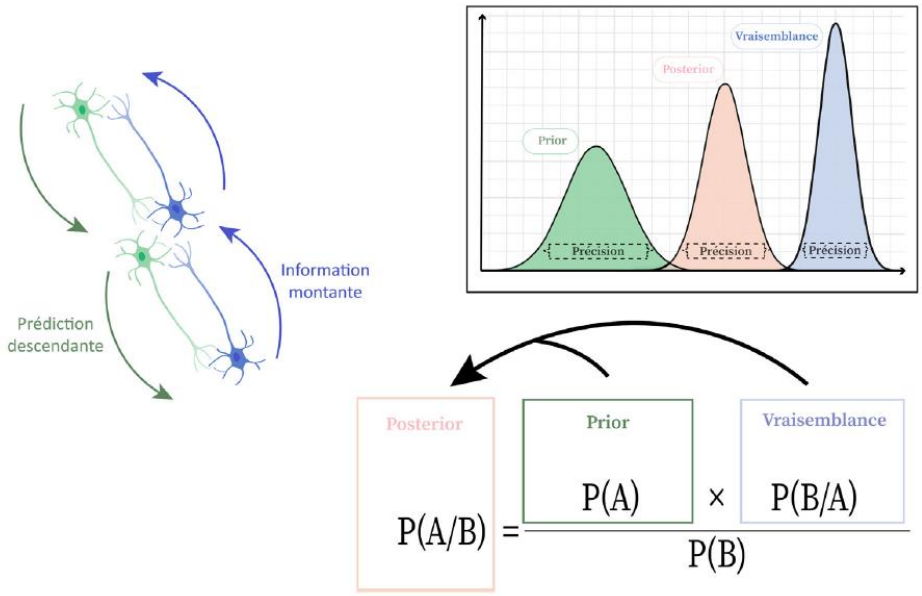

Fig. 1. « À gauche, exemple d'un modèle prototypique du traitement prédictif au sein d'un réseau schématique avec quatre neurones : au sein de ce modèle, les informations montantes (flèches bleu) issues du traitement des signaux sensoriels aux niveaux inférieurs sont communiquées aux neurones des niveaux supérieurs dans la hiérarchie corticale, et les prédictions descendantes (flèches verte) issues des croyances provenant de niveaux supérieurs sont communiquées aux neurones des niveaux inférieurs. » À droite : le théorème de Bayes, la probabilité d'un événement, ou croyance postérieure (distribution en rose) est prédite selon sa vraisemblance et les croyances antérieures associées à cet événement, ou prior (distribution en vert). Dans un environnement dynamique, l'évolution des croyances postérieures est ainsi dépendante du type d'information sensorielle nouvelle acquises, et du type de croyance antérieure utilisée pour réaliser l'inférence bayésienne. (Bottemanne et al., 2022).

Geurts et al. (2022) ont testé l'hypothèse selon laquelle la confiance est basée sur une distribution de probabilité représenté dans l'activité neuronale. Principalement avec une tâche de d'estimation de l'orientation d'un stimulus pendant que l'activité corticale des sujets était mesurée par IRM. Ces auteurs ont montré que la confiance comportementale suit le degré d'incertitude contenu dans l'activité de la population neuronale du cortex visuel, ce qui suggère que les observateurs ont eu accès au degré d'imprécision de leurs représentations corticales visuelles du stimulus et ont pu en rendre compte. De plus, l'activité dans le dACC, le dAI et le rlPFC est modulée à la fois par cette incertitude et par la confiance rapportée de manière prédite par le modèle bayésien, ce qui suggère que ces régions sont impliquées dans le calcul de la confiance à partir de l'incertitude sensorielle (Geurts et al, 2021).

Une théorie unificatrice ?

Si d'autres études comme celle de Wei Ji Ma et al (2006) soutiennent sur base d'expérience que les neurones représentent des distributions de probabilité et combinent ces distributions selon une approximation proche de la règle de Bayes, d'autres études sont plus mitigées et soulèvent la question de savoir pourquoi nos décisions s'écartent-elles souvent de l'optimalité bayésienne ? En effet, nous sommes régulièrement victimes de nos biais cognitifs qui nous mènent à des attitudes

et comportements irrationnels. Comme le rappelle Kahneman dans son livre « Thinking fast and slow » « qui porte en grande partie sur les biais d'intuition », « nous sommes souvent confiants même lorsque nous avons tort, et un observateur objectif est plus susceptible de détecter nos erreurs que nous ne le sommes » (Khaneman, 2011). Plus contemporains, la neuroscientifique Tali Sharot et ses collègues ont récemment publié un article qui met en exergue les corrélats neuronaux du biais de confirmation, « ce biais est corrélés à une réduction de la sensibilité neuronale à la force de l'opinion de l'autre dans le préfrontal postérieur médial quand les opinions sont discordantes » (Kappes, 2020).

En sciences cognitives, la littérature déborde de ce genre d'idées, il est dès lors difficile de les concilier avec l'idée d'un cerveau bayésien optimal dont la théorie se voudrait unificatrice. Si elle n'est probablement pas unificatrice d'un certain point de vue, elle a cependant permis d'éclairer ce que Dehaene (2012) appelle « le scandale de l'induction », un débat majeur au sujet de l'apprentissage du langage. À ce sujet, Tenenbaum (2015) dans son article passionnant « How to grow a mind : Statistics, Structure, and Abstraction » tente de répondre à une question connue depuis Platon : « comment nos esprits obtiennent-il autant avec si peu ? ». Il suggère une nouvelle manière d'envisager le développement cognitif à l'aide d'un modèle hiérarchique bayésien « qui peut découvrir des cadres théoriques définis par n'importe quel nombre de classes de variables et n'importe quel modèle de régularités par paires sur la façon dont les variables de ces classes ont tendance à être connectées. » (Tenenbaum, 2015). De manière plus générale, « les modèles hiérarchiques non paramétriques répondent au principal défi auquel les apprenants humains sont confrontés lorsque les connaissances augmentent au cours d'une vie : l'équilibre entre la contrainte et la flexibilité, ou la nécessité de restreindre les hypothèses disponibles pour la génération à tout moment avec la capacité d'élargir ses espaces d'hypothèses » (Tenenbaum, 2015).

Il appelle lui-même à la vigilance : la théorie bayésienne « ne signifie pas que l'esprit peut mettre en œuvre toute inférence bayésienne », et il rappelle qu' « en revanche, dans les tâches qui exigent des manipulations conscientes explicites des probabilités sous forme de quantités numériques - une invention culturelle récente que peu de gens maîtrisent, et seulement après un entraînement sophistiqué - les jugements peuvent être notoirement biaisés par rapport aux normes bayésiennes ».

De plus, en mentionnant que le bayesianisme semble être « le mot d'ordre de la nouvelle sciences cognitive », Kolanski (2021) rappelle que les théories unificatrices sont intelligentes et attrayantes, mais elles sont également dangereuses car elles tendent à monopoliser et à imposer une vision de la "pensée juste". Au même titre que le débat impliquant le fréquentisme, il semblerait qu'il n'y a ait pas de dernier mot en sciences. Les idées ne sont pas discrètes mais

continues et l'honnêteté intellectuelle et la collaboration qui caractérisent la raison scientifique nous guidera toujours, je l'espère, vers un monde plus intellectuellement et plus matériellement confortable.

Bibliographie

Bottemanne, H., Longuet, Y., & Gauld, C. (2022). The predictive mind: An introduction to Bayesian Brain Theory. L'encephale.

Clark, A. (2015). Surfing uncertainty: Prediction, action, and the embodied mind. Oxford University Press.

De Scheemaekere, X. (2009). Les fondements philosophiques du concept de probabilité (No. 09-025. RS). ULB--Universite Libre de Bruxelles.

Égré, P. (2017). Isabelle Drouet (ed.), Le bayésianisme aujourd'hui. Fondements et pratiques. Œconomia. History, Methodology, Philosophy, (7-3), 453-458.

Friston, K. (2005). A theory of cortical responses. Philosophical transactions of the Royal Society B: Biological sciences, 360(1456), 815-836.

Geurts, L. S., Cooke, J. R., van Bergen, R. S., & Jehee, J. F. (2022). Subjective confidence reflects representation of Bayesian probability in cortex. Nature Human Behaviour, 1-12.

Hoang, L. N. (2018). La formule du savoir: une philosophie unifiée du savoir fondée sur le théorème de Bayes. EDP sciences.

Kahneman, D. (2011). Thinking, fast and slow. Macmillan.

Kappes, A., Harvey, A. H., Lohrenz, T., Montague, P. R., & Sharot, T. (2020). Confirmation bias in the utilization of others' opinion strength. Nature neuroscience, 23(1), 130-137.

Laplace, P. S. (1774). Mémoire sur la probabilité de causes par les évenements. Mémoire de l'académie royale des sciences.

Ma, W. J., Beck, J. M., Latham, P. E., & Pouget, A. (2006). Bayesian inference with probabilistic population codes. Nature neuroscience, 9(11), 1432-1438.

Morais, J., & Kolinsky, R. (2021). Seeing thought in the future: Literate forecasting and forecasting literacy. Journal of Cultural Cognitive Science, 5(2), 229-265.

Rall, W. (1962). Electrophysiology of a dendritic neuron model. Biophysical journal, 2(2 Pt 2), 145.

Roussel, V. (2019). Introduction à l'inférence bayésienne-Cours 1: axiomatisation.

Sprenger, J. (2016). Bayésianisme versus fréquentisme en inférence statistique. Le Bayésianisme aujourd'hui, 167-192.