English translation first. French original version below.

The Bayesian Brain: A Unifying Theory in Cognitive Science?

Giacomina (Mina) Grandolfo

Philosophy of Cognitive Sciences (PHILB315), ULB, 2022

Introduction

It was through discovering Stanislas Dehaene's first online course at the College de France, "Le cerveau statisticien: la revolution Bayesienne en sciences cognitives", that I became interested in the subject of this essay. Any researcher who becomes interested in Bayesianism is quickly struck by the richness and complexity of this universe. I am glad to be only at the beginning of my discoveries, already aspiring to integrate this mode of rational reasoning into my daily life and to use this statistical approach to analyse, I hope, my future research. This "formula of knowledge" (Le Nguyen, 2018) raises, to my mind, two lines of questioning in the philosophy of science. The first concerns the statistical analysis that opposes Bayesians and frequentists. The second rests on the question of the unifying power of "Bayesian brain theory" in cognitive science.

I will begin this essay with a description of Bayesianism, will say a brief word on the statistical debate, and will then turn to "Bayesian brain theory" and the debate it raises.

Bayesianism

Thomas Bayes, an 18th-century mathematician, gave his name to Bayesian theory. This theory concerns the probability of a hypothesis. The formula written by Bayes is not the one used today when this theorem is invoked. It is in fact to the mathematician Pierre Simon Laplace that we owe the final formula, a few years later. He inverted the original formula of Bayes, which he called "inverse probability". Its particularity is that it seeks to work backwards from the "states of the world". Contrary to frequentist formulas that seek, through deductive logic, to propagate the uncertainty of events from their causes to their consequences, Bayesian logic uses induction to establish the probability of a cause given its consequence. In his "Memoir on the probability of causes from events", Laplace writes: "I propose to determine the probability of causes from events, a new subject in many respects and that deserves all the more to be cultivated as it is principally under this point of view that the science of chance can be useful in civil life" (Laplace, 1774).

His contemporary physicist Edwin Thompson Jaynes then formulated a series of implications for Bayesian methods, grounded in the Cox-Jaynes theorem and its central notion of plausibility (Roussel, 2019). In his first chapter titled "Deductive and Plausible Reasoning", Jaynes (2003)

introduces his ideas through the trivial example of a policeman who witnesses a theft and immediately qualifies as dishonest someone he sees exiting through the window of a jewellery store, a bag in hand and the alarm ringing. Jaynes writes: "In this book we shall be able to report useful and encouraging new progress, in which conflicting intuitive judgements are replaced by definite theorems, and ad hoc procedures are replaced by rules that are determined uniquely by some very elementary, and virtually inescapable, criteria of rationality. All discussions of these matters begin by giving examples of the contrast between deductive and plausible reasoning."

Ascribing, as Aristotle's Organon (4th century BC) does, deductive reasoning to ultimately the repeated application of two strong syllogisms, Jaynes notes that these two reasonings are those we would want to use all the time, but we almost never have the right amount of information to be entitled to them. We often fall into logically weaker reasonings (Jaynes, 2003): "If A is true, then B is true; B is true; therefore A becomes more plausible". In this last reasoning, there is no evidence to prove that A is true, but the verification of one of its consequences (B is true) increases our confidence in A (Jaynes, 2003).

It would therefore seem that statistical language has always sought a certain capacity to grasp uncertainty. As De Scheemaekere (2019) recalls in her "Philosophical foundations of the concept of probability", "uncertainty is a major component of life", and probability is an essential element in coping with it, not only from a scientific point of view but also from a philosophical one. It seems to me that this is precisely what Bayesian statistics offer, with a conception of reasoning that includes the "notion of a reasonable a priori degree of belief" (Dehaene, 2012). Dehaene (2012) expresses this as "the measure of subjective knowledge, that is, the plausibility of one interpretation relative to another". According to him, "if the evolution of the brain has led to coherent rules of manipulation of plausibility, these rules must approximate the fundamental rules of probability" (Dehaene, 2012).

These rules are mathematical foundations that I do not find it necessary to restate in this brief essay. I will, however, recall the Bayes formula as a tribute to its mathematical elegance and to the ink it has caused to flow. It is particular in that observations and hypotheses play strictly symmetrical roles, and one can therefore invert the procedure: given the data of the hypothesis, what is the probability of the hypothesis?

One can write it as follows, with D for data and H for hypothesis: $p(H|D)$ is proportional to $p(D|H)$ times $p(H)$. One can read it as: the probability of the hypothesis given the data is proportional to the probability of the data given the hypothesis, times the probability of the hypothesis. Dehaene (2012) explains that the right-hand $p(H)$ is the prior probability of the hypothesis H, its plausibility before even having the data (D). On the left-hand side, the posterior probability is the new plausibility of the hypothesis that appears after observing the data D. "A posteriori" does not refer to temporality (one may have had the data for a long time) but to the correct manner of revising beliefs in light of the data D (Dehaene, 2012). This is one of the key points of this formula: it updates with each new data point received to favour, through the Bayes factor, one hypothesis over another. Some call this "the dance of credences" (Le Nguyen, 2018).

Dehaene praises this formula by reminding us of a fundamental concept from the philosophy of science: a theory must be falsifiable. What explains everything explains nothing. Indeed, the mathematical system of Bayesian theory is such that it will always favour the hypothesis most parsimonious in parameters. This explains the frequent reference to Occam's razor when one reads about Bayesianism. This philosophical principle, on which the formula rests in part, holds that the simplest solution should always be preferred; the Bayesian formula is constructed so as to apply this principle.

Frequentist and Bayesian statistical approaches

Bayesianism and frequentism (called the classical approach) are two major schools of statistical inference based on "philosophical postulates and mathematical methods that are fundamentally different" (Sprenger, 2016). As explained above, Bayesian inference is based on the credibility of a hypothesis, whereas "a frequentist inference is valid if, in the long run, the procedure that underlies it only rarely leads to incorrect conclusions" (Sprenger, 2016). Even though Bayesian methods have been used for about thirty years "with growing success in domains as diverse as genomics, medical diagnosis, geosciences, or cognitive science (this list is far from exhaustive)" (Drouet, 2016), and even though "Bayesians seem to win hands down from a purely fundamental point of view, it is not obvious that their methods constitute the best solutions for scientific practice" (Sprenger, 2016). It seems that it is, among other things, the fear of introducing some subjectivity through the degree of belief into scientific reasoning that frightens the followers of Fisher, Pearson, and Neyman. A part of the scientific community would "fear that external interests affect inferences" (Sprenger, 2016).

Despite its uncontested reign since the 20th century, frequentism is the object of numerous critiques, one of the main being the "selection bias caused by the fact that only conclusive studies are published" (Le Nguyen, 2018). Le Nguyen also raises, in an amusing way, a critique of the p-value: "if we took the p-value really seriously, we would end up rejecting all scientific theories, including those that are true". According to him, science tells us that theories must be tested "again and again"; "but with a threshold of 0.00003%, each experiment has a 0.00003% probability of rejecting a true theory it tests". If this principle is followed to the letter, a true theory will end up being rejected after a few million trials.

For its part, does Bayesianism risk weakening science with an uncontrollable degree of subjectivity? It is difficult to settle the debate; fortunately, the majority of the scientific community is animated by a desire for intellectual honesty and seems to constantly reshape science, slowly but surely toward the most reasonable ideas.

The Bayesian brain

The literature on this subject shows the fundamental role of cognitive science as a bridge between a mathematical problem and the philosophical questions it raises. Indeed, the mathematically-rooted theory of the Bayesian brain, which also raises deep philosophical questions, proposes to explain the main processes underlying the functioning of the mind, at the

heart of cognitive science. Dehaene (2012) goes as far as speaking of a "Bayesian revolution" on this subject. It is a computational approach derived from the principles of predictive processing. It proposes a mechanistic and mathematical formulation of these cognitive processes and assumes that the brain encodes beliefs (probabilistic states) to generate predictions about sensory inputs, then uses prediction errors to update those beliefs (Bottemanne et al., 2021). Bayesian brain theory is today one of the most popular approaches in neuroscience for representing the complex processes underlying perception, decision-making, and learning, three fundamental domains of cognition (Clark, 2015).

Moreover, this theory rests on the idea that the brain uses beliefs to generate predictions (also called anticipations or expectations) about sensory inputs the body will experience (Friston, 2005). These beliefs are then updated in response to the prediction errors triggered by sensory inputs, allowing the brain to adapt to changes in its environment. In other words, applied to predictive processing, Bayesian theory allows us to understand how the brain generates inferences to determine the probability of the sensory information it will receive as experience unfolds, and how it modifies its beliefs in light of this information (Bottemanne et al., 2022).

Neural correlates

The neuroscientist Wilfrid Rall demonstrated, in parallel, that dendritic arborisations at the extremities of neurons modify synaptic processing and electrical information transfer (Rall, 1962). These discoveries, from the beginning to the middle of the 20th century, revolutionised our understanding of the role of neurons by showing that brain activity is generated by the automated processing of information within neural networks, and that synaptic connections determine the type of message transmitted by brain activity (Bottemanne et al., 2022).

Geurts et al. (2022) tested the hypothesis that confidence is based on a probability distribution represented in neural activity. Primarily with a task of estimating the orientation of a stimulus while cortical activity was measured by fMRI, these authors showed that behavioural confidence follows the degree of uncertainty contained in the neural population activity of the visual cortex, suggesting that observers have access to the degree of imprecision of their cortical visual representations of the stimulus and can account for it. Furthermore, activity in the dACC, dAI, and rlPFC is modulated both by this uncertainty and by reported confidence in a manner predicted by the Bayesian model, suggesting that these regions are involved in the computation of confidence from sensory uncertainty (Geurts et al., 2021).

A unifying theory?

If other studies such as that of Wei Ji Ma et al. (2006) support, on the basis of experiment, that neurons represent probability distributions and combine these distributions according to an approximation close to the Bayes rule, other studies are more mixed and raise the question: why do our decisions often depart from Bayesian optimality? Indeed, we are regularly victims of our cognitive biases, which lead us to irrational attitudes and behaviours. As Kahneman reminds

us in his book "Thinking, Fast and Slow", which "deals largely with intuition biases", "we are often confident even when we are wrong, and an objective observer is more likely to detect our errors than we are" (Kahneman, 2011). More recently, the neuroscientist Tali Sharot and her colleagues recently published an article highlighting the neural correlates of confirmation bias: "this bias is correlated with a reduction in neural sensitivity to the strength of the opinion of another in the posterior medial prefrontal cortex when opinions are discordant" (Kappes, 2020).

In cognitive science, the literature is full of this kind of idea; it is therefore difficult to reconcile them with the idea of an optimal Bayesian brain whose theory would be unifying. Even if it is probably not unifying from a certain point of view, it has nonetheless allowed us to shed light on what Dehaene (2012) calls "the scandal of induction", a major debate concerning language learning. On this subject, Tenenbaum (2015), in his fascinating article "How to grow a mind: Statistics, structure, and abstraction", attempts to answer a question known since Plato: "how do our minds get so much from so little?". He suggests a new way of envisaging cognitive development with the help of a hierarchical Bayesian model "that can discover theoretical frameworks defined by any number of classes of variables and any pattern of pairwise regularities about how variables in these classes tend to be connected" (Tenenbaum, 2015). More generally, "non-parametric hierarchical models meet the main challenge that human learners face as knowledge grows over a lifetime: balancing constraint and flexibility, or the need to restrict available hypotheses for generation at any moment with the capacity to expand one's hypothesis spaces" (Tenenbaum, 2015).

He himself calls for vigilance: Bayesian theory "does not mean that the mind can implement any Bayesian inference"; and he reminds us that "in contrast, in tasks that demand explicit conscious manipulations of probabilities as numerical quantities, a recent cultural invention that few people master, and only after sophisticated training, judgements can be notoriously biased relative to Bayesian norms".

Moreover, mentioning that Bayesianism seems to be "the watchword of the new cognitive science", Kolinsky (2021) reminds us that unifying theories are intelligent and attractive, but they are also dangerous because they tend to monopolise and impose a vision of "correct thinking". Just as with the debate involving frequentism, there seems to be no final word in science. Ideas are not discrete but continuous, and the intellectual honesty and collaboration that characterise scientific reason will always guide us, I hope, toward a world that is intellectually and materially more comfortable.

UNIVERSITÉ LIBRE DE BRUXELLES

Devoir de Philosophie des Sciences

Professeur :
Axel CLEEREMANS
Jean-Noël Missa

Étudiante :
Giacominao GRANDOLFO - 000449111

PHILB315 - Philosophie des sciences cognitives

Faculté des sciences Psychologiques et de l'Éducation - Année académique 2021-2022

Introduction

C'est en découvrant le premier cours en ligne de Stanislas Dehaene au collège de France « Le cerveau statisticien : la révolution Bayésienne en sciences cognitives » que je me suis intéressée au sujet de ce présent travail. Tout chercheur qui porte de l'intérêt au bayésianisme sera très vite saisi de la richesse et la complexité de cet univers. Je me réjouis de n'être qu'au début de mes découvertes, aspirant déjà à intégrer ce mode de raisonnement rationnel à mon quotidien ainsi qu'à utiliser cette approche statistique pour analyser, je l'espère, mes futures recherches. Cette « formule du savoir » (Le Nguyen, 2018) soulève à mon sens deux axes de questionnement en philosophie des sciences. Le premier concerne l'analyse statistique qui oppose bayésiens et fréquentistes. Le second repose sur la question du pouvoir unificateur de « la théorie du cerveau bayésien » en sciences cognitives.

Je commencerai cette dissertation par une description du bayésianisme, je dirai un mot bref sur le débat statistique pour ensuite m'intéresser à «la théorie du cerveau bayésien » et au débat qu'elle soulève.

Le bayésianisme

Thomas Bayes, un mathématicien du 18ème a donné son nom à la théorie bayésienne. Cette théorie concerne la probabilité d'une hypothèse. La formule écrite par Bayes n'est pas celle que l'on utilise aujourd'hui lorsqu'on évoque ce théorème. En réalité, c'est au mathématicien Pierre Simon Laplace que l'on doit la formule finale quelques années plus tard. Il retourne la formule originale de Bayes qu'il appelle d'ailleurs « la probabilité inverse ». Sa particularité est de vouloir remonter en marche arrière depuis les « états du monde ». Contrairement aux formules fréquentistes qui cherchent à travers une logique déductive à propager l'incertitude des évènements depuis leur cause jusqu'à leur conséquence, la logique bayésienne utilise l'induction pour établir la probabilité d'une cause sachant sa conséquence. Dans son livre « Mémoire sur la probabilité des causes par les évènements », Laplace écrit de fait « je me propose de déterminer la probabilité des causes par les évènements, matière neuve à bien des égards et qui mérite d'autant plus d'être cultivée que c'est principalement sous ce point de vue que la science des hasards peut être utile dans la vie civile » (Laplace, 1749).

Ensuite, son contemporainphysicien Edwin Thompson Jaynes formuleune série d'implications pour les méthodes bayésiennes en se fondant sur le théorème de Cox-Jaynes et sa notion centrale de plausibilité (Roussel, 2019). Dans son premier chapitre intitulé « Raisonnement déductible et plausible », Jaynes(2003) introduit ses idées par l'exemple trivial d'un policier qui

assiste à une scène de vol et qualifie immédiatement de malhonnête une personne qu'il voit sortir par la fenêtre de la bijouterie, un sac à la main et l'alarme retentissante. « Dans cet ouvrage, nous serons en mesure de faire état de nouveaux progrès utiles et encourageants, dans lesquels les jugements intuitifs contradictoires sont remplacés par des théorèmes définis, et les procédures ad hoc sont remplacées par des règles qui sont déterminées de manière unique par de très élémentaires – et pratiquement incontournables – critères de rationalités. Toutes les discussions sur ces questions commencent par donner des exemples du contraste entre le raisonnement déductif et le raisonnement plausible. » (Jaynes 2003).

Selon lui, comme on l'attribue généralement à l'Organon d'Aristote (4è siècle B. J.-C.), le raisonnement déductif peut être analysé en définitive comme l'application répétée de deux syllogismes forts :

1: Deductive and Plausible Reasoning

$$\frac{\begin{array}{c}\text{If } A \text{ is true, then } B \text{ is true}\\ A \text{ is true}\end{array}}{\text{Therefore, } B \text{ is true}} \qquad (1\text{–}1)$$

and its inverse:

$$\frac{\begin{array}{c}\text{If } A \text{ is true, then } B \text{ is true}\\ B \text{ is false}\end{array}}{\text{Therefore, } A \text{ is false}} \qquad (1\text{–}2)$$

Ces deux raisonnements sont ceux que l'on utiliserait tout le temps mais nous n'avons pratiquement jamais la bonne quantité d'information pour nous les permettre. Nous tombons souvent dans des raisonnements logiquement plus faibles (Jaynes, 2003) :

$$\frac{\begin{array}{c}\text{If } A \text{ is true, then } B \text{ is true}\\ B \text{ is true}\end{array}}{\text{Therefore, } A \text{ becomes more plausible}} \qquad (1\text{–}3)$$

Dans ce dernier raisonnement, il n'y a pas d'évidence pour prouver que A est vrai mais la vérification de l'une de ses conséquences (B is true) augmente notre confiance en A (Jaynes, 2003).

Ainsi, il semblerait que le langage statistique ait toujours été à la recherche d'une certaine capacité à saisir l'incertitude. Comme le rappelle De Scheemaekere (2019) dans ses « fondements philosophiques du concept de probabilité », « l'incertitude est une composante majeure de la vie», la probabilité est un élément essentiel pour y faire face, non seulement d'un point de vue scientifique mais aussi philosophique. Il me semble que c'est précisément ce que propose la

statistique bayésienne avec une conception du raisonnement qui inclut la « notion de degré raisonnable de croyance à priori » (Dehaene, 2012). Dehaene (2012) exprime cela par « la mesure de la connaissance subjective, c'est-à-dire la plausibilité d'une interprétation par rapport à une autre ». Selon lui, « si l'évolution du cerveau a conduit à des règles cohérentes de manipulation de la plausibilité, ces règles doivent approximer les règles fondamentales de la probabilité » (Dehaene, 2012).

Ces règles sont des fondements mathématiques qu'il ne me semble pas utile de rappeler dans ce bref travail. Je rappellerai cependant la formule de Bayes en hommage à son élégance mathématique et à l'encre qu'elle a fait couler depuis. Elle a de particulier que les observations et les hypothèses jouent des rôles strictement symétriques et qu'on peut dès lors inverser le procédé: étant donné les données de l'hypothèse, quelle est la probabilité de l'hypothèse ?

On peut l'écrire comme ceci avec D pour données et H pour hypothèse :

$$p(H|D) \ \alpha \ p(D|H)\, p(H)$$

On peut la lire comme ceci : la probabilité de l'hypothèse étant donné les données est proportionnelle à la probabilité des données étant donnée l'hypothèse fois la probabilité de l'hypothèse. Dehaene (2012) explique qu'H, à droite est la probabilité à priori (prior en anglais) de l'hypothèse H, sa plausibilité avant même d'avoir les données (D). À gauche de la formule, c'est la probabilité « à postériori » qui est la nouvelle plausibilité de l'hypothèse qui apparait après avoir observé les données D. « À postériori » ne fait pas référence à la temporalité (on avait peut-être les données depuis longtemps) mais à la bonne manière de réviser nos croyances en tenant comptedes données D (Dehaene, 2012). C'est en fait un des points clés de cette formule, elle se met à jour à chaque nouvelle donnée reçue pour favoriser à travers le facteur de Bayes une hypothèse plutôt qu'une autre. Certains appellent cela la danse des crédances (Le Nguyen, 2018).

Dehaene fait l'éloge de cette formule en nous rappelant un concept fondamental de philosophie des sciences qui énonce qu'une théorie doit être falsifiable. Ce qui explique tout, n'explique rien. En effet, le système mathématique de la théorie bayésienne est tel qu'il privilégiera toujours l'hypothèse la plus parcimonieuse en termes de paramètres. Cela explique la référence fréquente au rasoir d'Ockham lorsque l'on se documente sur la bayésianisme. Ce principe philosophique veut que la solution la plus simple soit toujours préférée, la formule bayésienne est construite de manière à appliquer ce principe.

Approche statistique fréquentiste et bayésienne

Le bayésiannisme et le fréquentisme (appelée l'approche classique) sont deux grandes écoles d'inférences statistique basées sur « des postulats philosophiques et des méthodes mathématiques fondamentalement différentes » (Sprenger, 2016). Comme expliqué plus haut, l'inférence bayésienne se base sur la crédibilité d'une hypothèse alors qu'« une inférence fréquentiste est valide si, sur le long terme, la procédure qui en est à la base ne mène que rarement à des conclusions incorrectes » (Sprenger, 2016). Même si les méthodes du bayesianisme sont utilisées depuis une trentaine d'années « avec un succès croissant dans des domaines aussi divers que la génomique, le diagnostic médical, les géosciences, ou les sciences cognitives (cette liste est loin d'être exhaustive) » (Drouet, 2016), et que « les bayésiens semblent gagner haut la main d'un point de vue purement fondamental, il n'est pas évident que leurs méthodes constituent les meilleures solutions pour la pratique scientifique» (Sprenger, 2016). Il semblerait que ce soit entre autres la crainte d'intégrer une certaine subjectivité à travers le degré de croyance dans un raisonnement scientifique qui effraye les adaptes de Fisher, Pearson et Neyman. Une partie de la communauté scientifique aurait « peur que des intérêts externes affectent les inférences » (Sprenger, 2016).

Malgré son règne sans partage depuis le XXème siècle, le fréquentisme fait l'objet de nombreuses critiques, l'une des principales étant celle du « biais de sélection causé par le fait que seuls les travaux conclusifs sont publiés » (Le Nguyen, 2018). Le Nguyen soulève également de manière amusante une critique de la p-valeur : « si l'on prenait la p-value vraiment au sérieux, alors on devrait finir par rejeter toutes les théories scientifiques, y compris celles qui sont vraies ». Selon lui, la science nous dit que les théories doivent être testées « encore et encore », « or, avec un seuil de 0,00003 %, chaque expérience a une probabilité 0,00003 % de rejeter une théorie vraie qu'elle teste ». Si on suit ce principe à la lettre, une théorie vraie finira par être rejetée au bout de quelques millions d'essais.

De son côté, le bayésianisme risque-t-il de fragiliser les sciences avec un degré de subjectivité incontrôlable ? Il semble difficile de trancher le débat ; fort heureusement, la majorité de la communauté scientifique est animée par un désir d'honnêteté intellectuelle et semble constamment remanier les sciences, lentement mais surement vers les idées les plus raisonnables.

Le cerveau bayésien

La littérature sur ce sujet laisse apparaître le rôle fondamental des sciences cognitives comme faisant le lien entre une problématique mathématique et les questions philosophiques

qu'elle soulève. Effectivement, la théorie d'origine mathématique du cerveau bayésien soulevant des questionnements philosophiques profonds se propose depuis quelques années d'expliquer les processus principaux qui sous-tendent le fonctionnement de l'esprit, au cœur des sciences cognitives. Dehaene (2012) ira jusqu'à parler de « révolution bayésienne » à son sujet. Elle est une approche computationnelle issue des principes du traitement prédictif. Elle propose une formulation mécanistique et mathématique de ces processus cognitifs et suppose que le cerveau encode des croyances (états probabilistes) pour générer des prédictions à propos des entrées sensorielles, puis utilise les erreurs de prédictions pour mettre à jour ses croyances (Bottemanne et al., 2021). La théorie du cerveau bayésien (Bayesian Brain theory) est aujourd'hui l'une des approches les plus populaires en neurosciences pour représenter les processus complexes sous-tendant la perception, la prise de décision et l'apprentissage, trois domaines fondamentaux de la cognition (Clark, 2015).

En outre, cette théorie repose sur l'idée que le cerveau utilise des croyances afin de générer des prédictions (aussi nommées anticipations, ou attentes) sur les entrées sensorielles que le corps va expérimenter (Friston, 2005). Ces croyances sont ensuite mises à jour en fonction des erreurs de prédiction provoquées par les entrées sensorielles, permettant au cerveau de s'adapter aux changements dans son environnement. En d'autres mots, appliquée au traitement prédictif, la théorie bayésienne permet de comprendre comment le cerveau génère des inférences afin de déterminer la probabilité des informations sensorielles qu'il va recevoir au fur et à mesure de ses expériences, et comment il modifie ses croyances en fonction de ces informations (Bottemanne et al., 2022).

Les corrélats neuronaux

Le neuroscientifique Wilfrid Rall démontre parallèlement que les arborisations dendritiques à l'extrémité des neurones modifient le traitement synaptique et le transfert d'information électrique (Rall, 1962). Ces découvertes du début au milieu du XXe siècle révolutionnent la compréhension du rôle des neurones en montrant que l'activité cérébrale est générée par le traitement automatisé de l'information au sein de réseaux neuronaux, et que les connexions synaptiques déterminent le type de message transmis par l'activité cérébrale (Bottemanne et al., 2022).

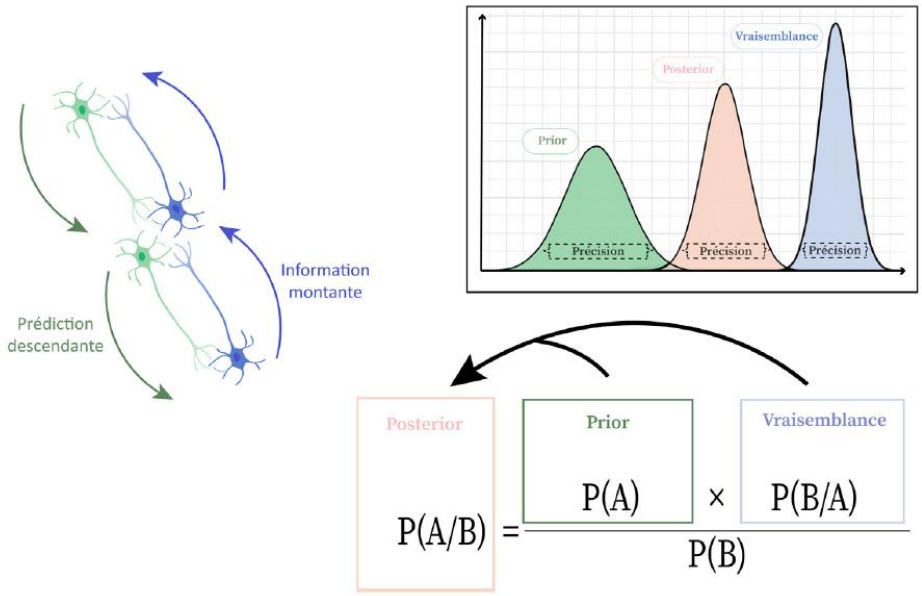

Fig. 1. « À gauche, exemple d'un modèle prototypique du traitement prédictif au sein d'un réseau schématique avec quatre neurones : au sein de ce modèle, les informations montantes (flèches bleu) issues du traitement des signaux sensoriels aux niveaux inférieurs sont communiquées aux neurones des niveaux supérieurs dans la hiérarchie corticale, et les prédictions descendantes (flèches verte) issues des croyances provenant de niveaux supérieurs sont communiquées aux neurones des niveaux inférieurs. » À droite : le théorème de Bayes, la probabilité d'un événement, ou croyance postérieure (distribution en rose) est prédite selon sa vraisemblance et les croyances antérieures associées à cet événement, ou prior (distribution en vert). Dans un environnement dynamique, l'évolution des croyances postérieures est ainsi dépendante du type d'information sensorielle nouvelle acquises, et du type de croyance antérieure utilisée pour réaliser l'inférence bayésienne. (Bottemanne et al., 2022).

Geurts et al. (2022) ont testé l'hypothèse selon laquelle la confiance est basée sur une distribution de probabilité représenté dans l'activité neuronale. Principalement avec une tâche de d'estimation de l'orientation d'un stimulus pendant que l'activité corticale des sujets était mesurée par IRM. Ces auteurs ont montré que la confiance comportementale suit le degré d'incertitude contenu dans l'activité de la population neuronale du cortex visuel, ce qui suggère que les observateurs ont eu accès au degré d'imprécision de leurs représentations corticales visuelles du stimulus et ont pu en rendre compte. De plus, l'activité dans le dACC, le dAI et le rlPFC est modulée à la fois par cette incertitude et par la confiance rapportée de manière prédite par le modèle bayésien, ce qui suggère que ces régions sont impliquées dans le calcul de la confiance à partir de l'incertitude sensorielle (Geurts et al, 2021).

Une théorie unificatrice ?

Si d'autres études comme celle de Wei Ji Ma et al (2006) soutiennent sur base d'expérience que les neurones représentent des distributions de probabilité et combinent ces distributions selon une approximation proche de la règle de Bayes, d'autres études sont plus mitigées et soulèvent la question de savoir pourquoi nos décisions s'écartent-elles souvent de l'optimalité bayésienne ? En effet, nous sommes régulièrement victimes de nos biais cognitifs qui nous mènent à des attitudes

et comportements irrationnels. Comme le rappelle Kahneman dans son livre « Thinking fast and slow » « qui porte en grande partie sur les biais d'intuition », « nous sommes souvent confiants même lorsque nous avons tort, et un observateur objectif est plus susceptible de détecter nos erreurs que nous ne le sommes » (Khaneman, 2011). Plus contemporains, la neuroscientifique Tali Sharot et ses collègues ont récemment publié un article qui met en exergue les corrélats neuronaux du biais de confirmation, « ce biais est corrélés à une réduction de la sensibilité neuronale à la force de l'opinion de l'autre dans le préfrontal postérieur médial quand les opinions sont discordantes » (Kappes, 2020).

En sciences cognitives, la littérature déborde de ce genre d'idées, il est dès lors difficile de les concilier avec l'idée d'un cerveau bayésien optimal dont la théorie se voudrait unificatrice. Si elle n'est probablement pas unificatrice d'un certain point de vue, elle a cependant permis d'éclairer ce que Dehaene (2012) appelle « le scandale de l'induction », un débat majeur au sujet de l'apprentissage du langage. À ce sujet, Tenenbaum (2015) dans son article passionnant « How to grow a mind : Statistics, Structure, and Abstraction » tente de répondre à une question connue depuis Platon : « comment nos esprits obtiennent-il autant avec si peu ? ». Il suggère une nouvelle manière d'envisager le développement cognitif à l'aide d'un modèle hiérarchique bayésien « qui peut découvrir des cadres théoriques définis par n'importe quel nombre de classes de variables et n'importe quel modèle de régularités par paires sur la façon dont les variables de ces classes ont tendance à être connectées. » (Tenenbaum, 2015). De manière plus générale, « les modèles hiérarchiques non paramétriques répondent au principal défi auquel les apprenants humains sont confrontés lorsque les connaissances augmentent au cours d'une vie : l'équilibre entre la contrainte et la flexibilité, ou la nécessité de restreindre les hypothèses disponibles pour la génération à tout moment avec la capacité d'élargir ses espaces d'hypothèses » (Tenenbaum, 2015).

Il appelle lui-même à la vigilance : la théorie bayésienne « ne signifie pas que l'esprit peut mettre en œuvre toute inférence bayésienne », et il rappelle qu' « en revanche, dans les tâches qui exigent des manipulations conscientes explicites des probabilités sous forme de quantités numériques - une invention culturelle récente que peu de gens maîtrisent, et seulement après un entraînement sophistiqué - les jugements peuvent être notoirement biaisés par rapport aux normes bayésiennes ».

De plus, en mentionnant que le bayesianisme semble être « le mot d'ordre de la nouvelle sciences cognitive », Kolanski (2021) rappelle que les théories unificatrices sont intelligentes et attrayantes, mais elles sont également dangereuses car elles tendent à monopoliser et à imposer une vision de la "pensée juste". Au même titre que le débat impliquant le fréquentisme, il semblerait qu'il n'y a ait pas de dernier mot en sciences. Les idées ne sont pas discrètes mais

continues et l'honnêteté intellectuelle et la collaboration qui caractérisent la raison scientifique nous guidera toujours, je l'espère, vers un monde plus intellectuellement et plus matériellement confortable.

Bibliographie

Bottemanne, H., Longuet, Y., & Gauld, C. (2022). The predictive mind: An introduction to Bayesian Brain Theory. L'encephale.

Clark, A. (2015). Surfing uncertainty: Prediction, action, and the embodied mind. Oxford University Press.

De Scheemaekere, X. (2009). Les fondements philosophiques du concept de probabilité (No. 09-025. RS). ULB--Universite Libre de Bruxelles.

Égré, P. (2017). Isabelle Drouet (ed.), Le bayésianisme aujourd'hui. Fondements et pratiques. Œconomia. History, Methodology, Philosophy, (7-3), 453-458.

Friston, K. (2005). A theory of cortical responses. Philosophical transactions of the Royal Society B: Biological sciences, 360(1456), 815-836.

Geurts, L. S., Cooke, J. R., van Bergen, R. S., & Jehee, J. F. (2022). Subjective confidence reflects representation of Bayesian probability in cortex. Nature Human Behaviour, 1-12.

Hoang, L. N. (2018). La formule du savoir: une philosophie unifiée du savoir fondée sur le théorème de Bayes. EDP sciences.

Kahneman, D. (2011). Thinking, fast and slow. Macmillan.

Kappes, A., Harvey, A. H., Lohrenz, T., Montague, P. R., & Sharot, T. (2020). Confirmation bias in the utilization of others' opinion strength. Nature neuroscience, 23(1), 130-137.

Laplace, P. S. (1774). Mémoire sur la probabilité de causes par les évenements. Mémoire de l'académie royale des sciences.

Ma, W. J., Beck, J. M., Latham, P. E., & Pouget, A. (2006). Bayesian inference with probabilistic population codes. Nature neuroscience, 9(11), 1432-1438.

Morais, J., & Kolinsky, R. (2021). Seeing thought in the future: Literate forecasting and forecasting literacy. Journal of Cultural Cognitive Science, 5(2), 229-265.

Rall, W. (1962). Electrophysiology of a dendritic neuron model. Biophysical journal, 2(2 Pt 2), 145.

Roussel, V. (2019). Introduction à l'inférence bayésienne-Cours 1: axiomatisation.

Sprenger, J. (2016). Bayésianisme versus fréquentisme en inférence statistique. Le Bayésianisme aujourd'hui, 167-192.